Améliorer la courbe d'apprentissage de R au delà de `Tidyverse` ?

Les packages `chart` et `flow`

Philippe Grosjean & Guyliann Engels

Université de Mons, Belgique
Laboratoire d'Écologie numérique des Milieux aquatiques
<Philippe.Grosjean@umons.ac.be><https://github.com/SciViews>

UMONS

Qui sommes-nous?

- Biologistes marins (coraux, plancton) à l'Université de Mons en Belgique.
- Développeurs en R (mainteneurs de 17 packages sur CRAN dont `tcltk2`, `mlearning`, `pastecs`, `zooimage`, `SciViews`, `svDialogs`, …)

UMONS

Qui sommes-nous?

- Enseignants, y compris biostatistiques et science des données (voir http://biodatascience-course.sciviews.org)

UMONS

En observant nos étudiants, nous en déduisons les aspects les plus difficiles dans l'apprentissage de R, et nous réfléchissons ensuite à la façon de les simplifier.

Deux exemples seront détaillés ici.

UMONS

Courbe d'apprentissage de R

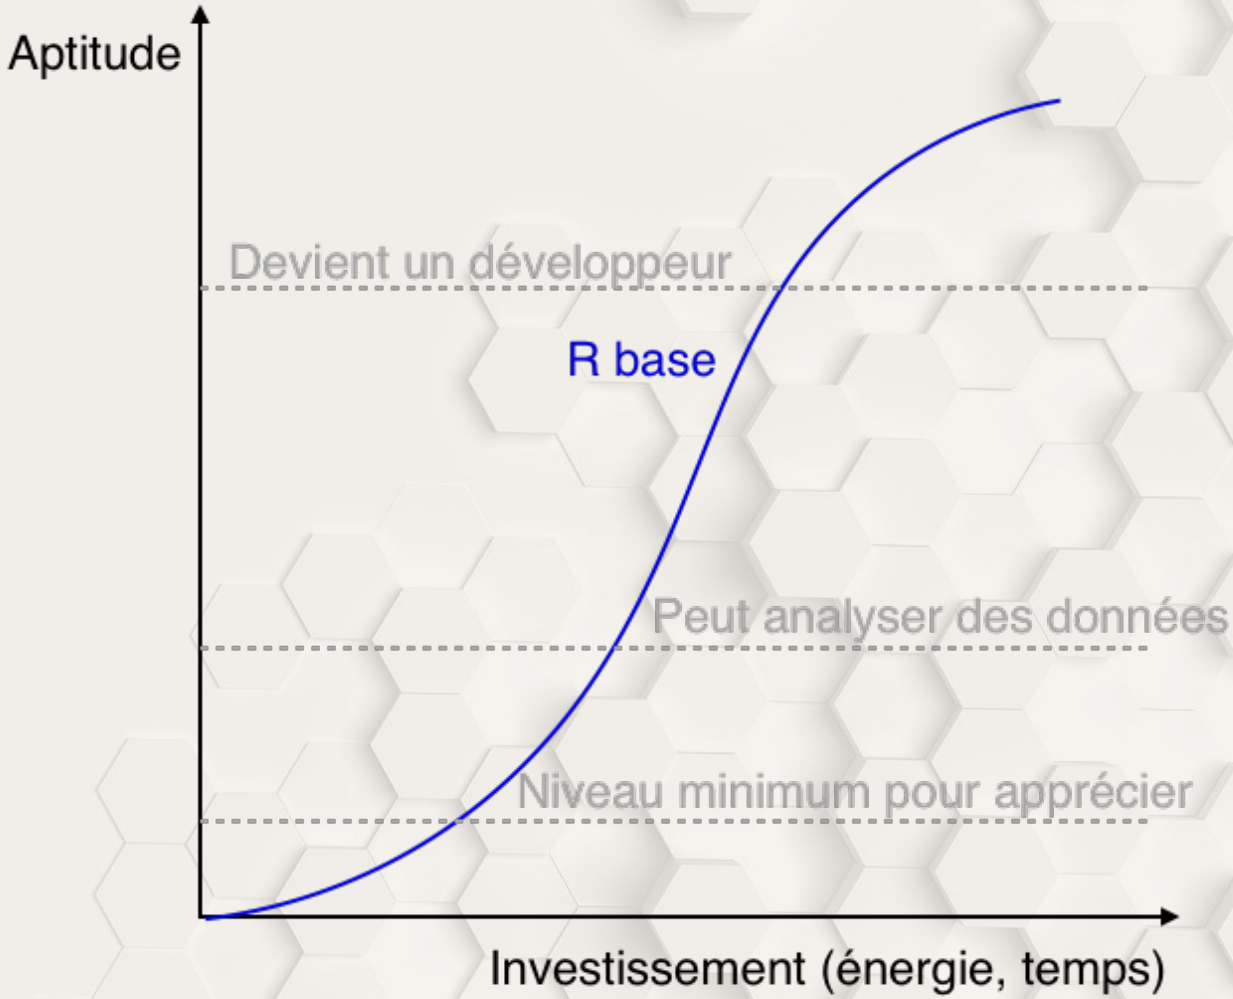

UMONS

Courbe d'apprentissage de R avec `Tidyverse`

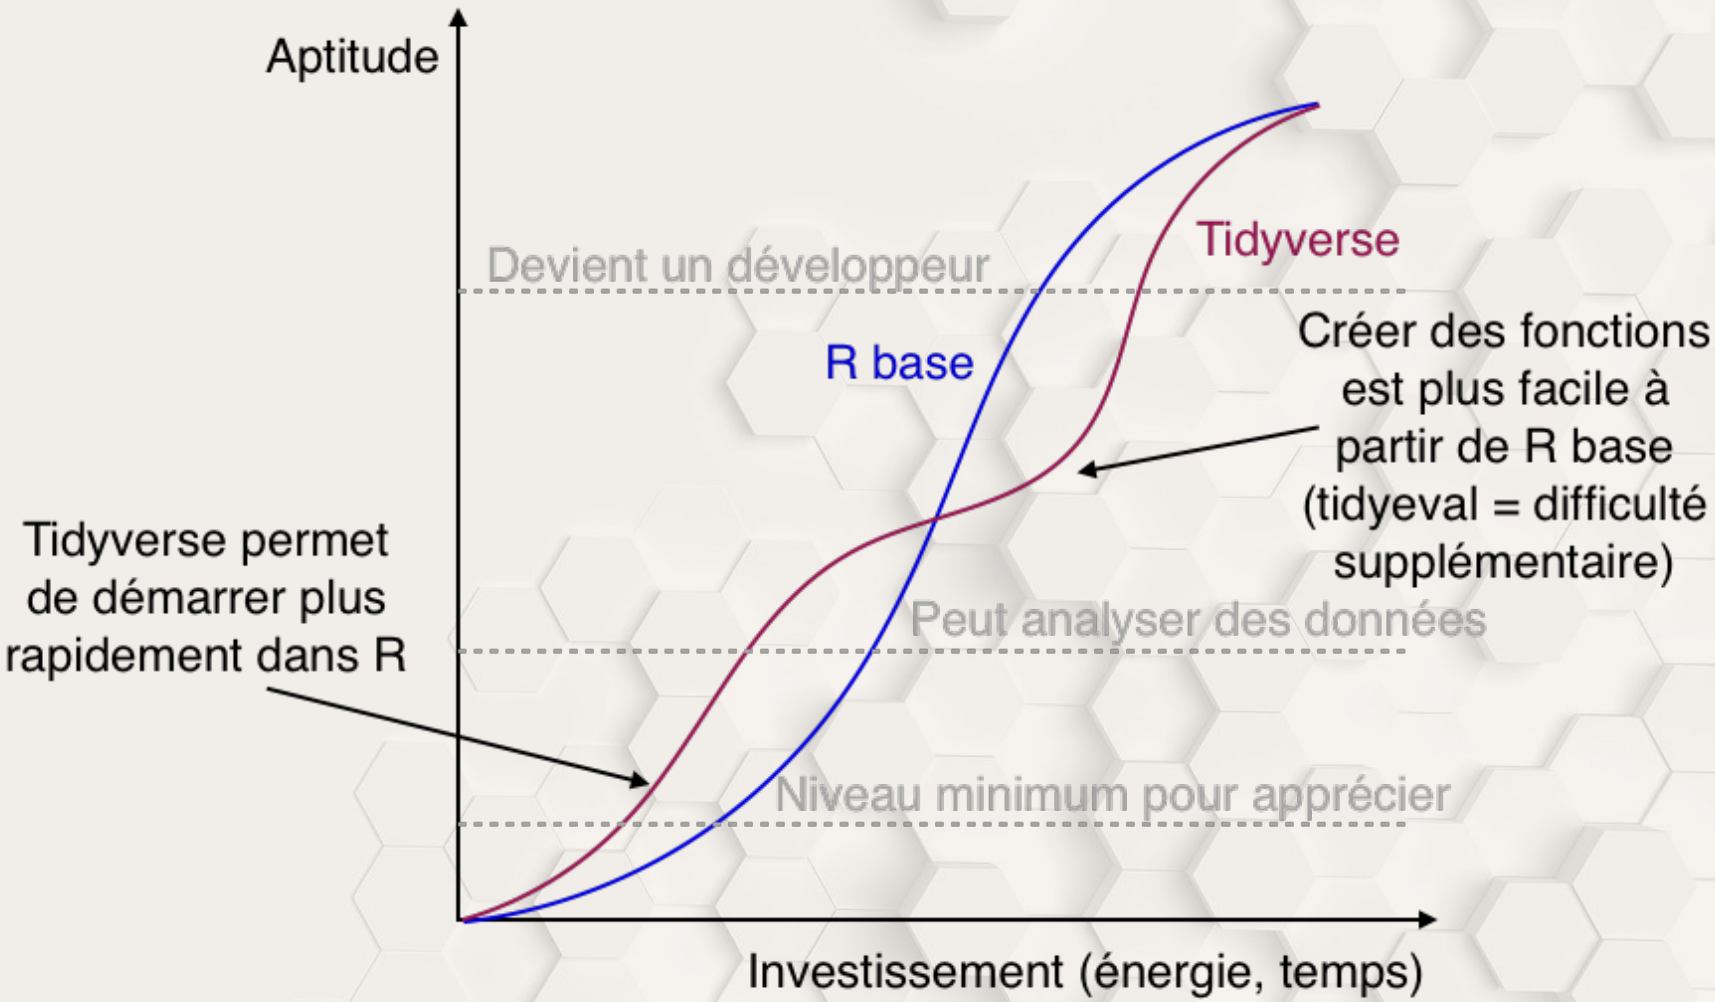

UMONS

Courbe d'apprentissage idéale

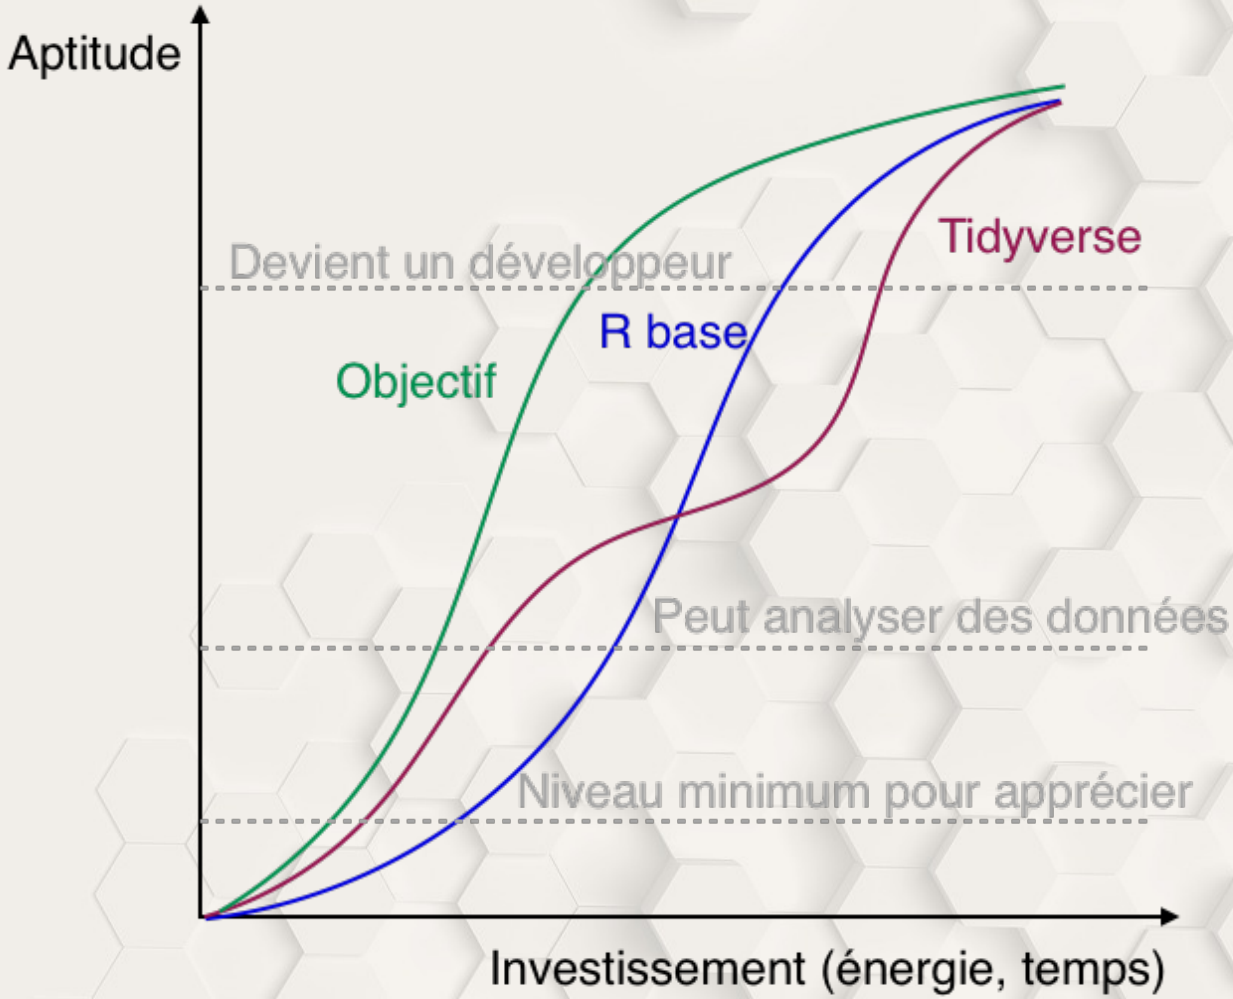

UMONS

Courbe d'apprentissage idéale

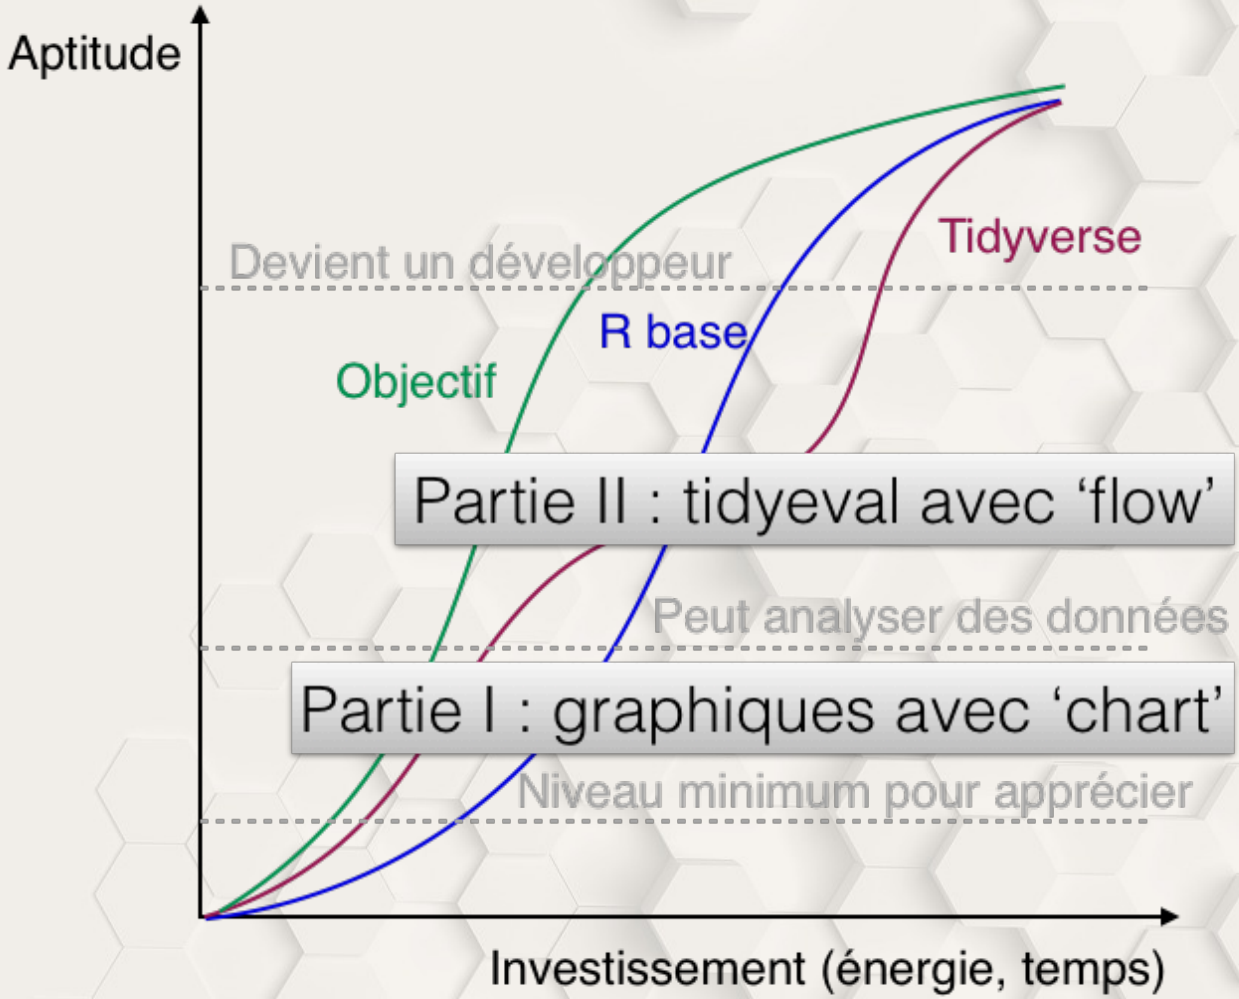

UMONS

Partie I : faciliter les graphiques R pour les débutants (package chart)

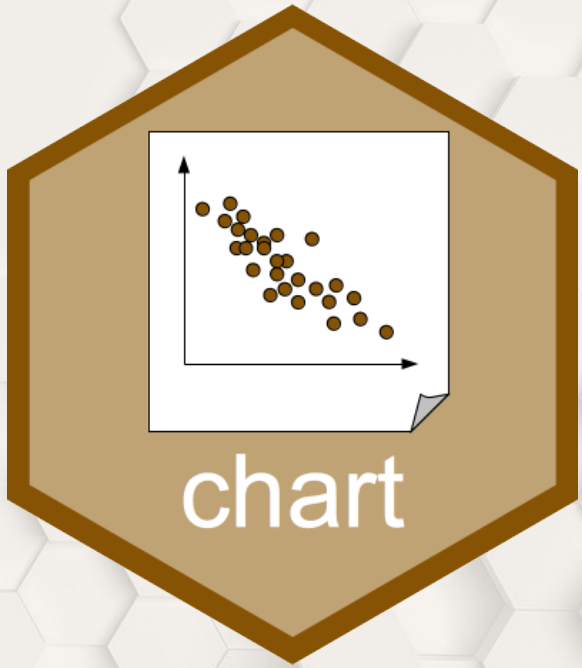

UMONS

Graphiques sous R

- Trois moteurs graphiques principaux **base R**, **lattice** & **ggplot2 (tidyverse)**
- Rendu différent, syntaxe différente, incompatibilités
- **ggplot2** comme première approche (cf. David Robinson)

David Robinson

Chief Data Scientist at DataCamp,

Don't teach built-in plotting to beginners (teach ggplot2)

I have some experience teaching R programming (see, for instance, my Introduction to the Tidyverse course). One of the atypical choices I make is to start by teaching Hadley Wickham's ggplot2 package, rather than the built-in R plotting.

Many times that I mention this choice to

Graphiques sous R - difficultés évitables pour les débutants

- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...

1. Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
2. Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
3. Est-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package `chart` quelques pistes d'amélioration des 3 points précédents.

UMONS

Graphiques sous R - difficultés évitables pour les débutants

- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...

1. Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
2. Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
3. Est-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package `chart` quelques pistes d'amélioration des 3 points précédents.

UMONS

Graphiques sous R - difficultés évitables pour les débutants

- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...

1. Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
2. Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
3. Est-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package `chart` quelques pistes d'amélioration des 3 points précédents.

UMONS

Graphiques sous R - difficultés évitables pour les débutants

- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...

1. Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
2. Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
3. Est-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package `chart` quelques pistes d'amélioration des 3 points précédents.

UMONS

Graphiques sous R - difficultés évitables pour les débutants

- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...

1. Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
2. Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
3. Est-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package `chart` *quelques pistes d'amélioration des 3 points précédents.*

UMONS

Analyse de la masse de squelette d'oursins

Jeu de données `urchin_bio` dans le package `data` chargé avec sa fonction `read()` (jeu de données) **enrichi** de métadonnées (e.g., **label** et **unités** des variables dans différentes langues) :

```
#install.packages("devtools")
#devtools::install_github("SciViews/data")
urchin <- data::read("urchin_bio", package = "data", lang = "FR")
```

Nous aurons besoin aussi de `tidyverse`, `chart` et de leurs dépendances :

```
#install.packages(c("tidyverse", "latticeExtra", "cowplot",
#  "pryr", "ggpubr", "ggplotify"))
#devtools::install_github("SciViews/chart")
library(tidyverse)
library(chart)
```

Mettons-nous maintenant dans la peau d'un débutant qui découvre les outils nécessaires pour analyser ces données…

UMONS

Premier graphique avec ggplot2

```
ggplot(data = urchin, aes(weight, skeleton)) +
  geom_point()
```

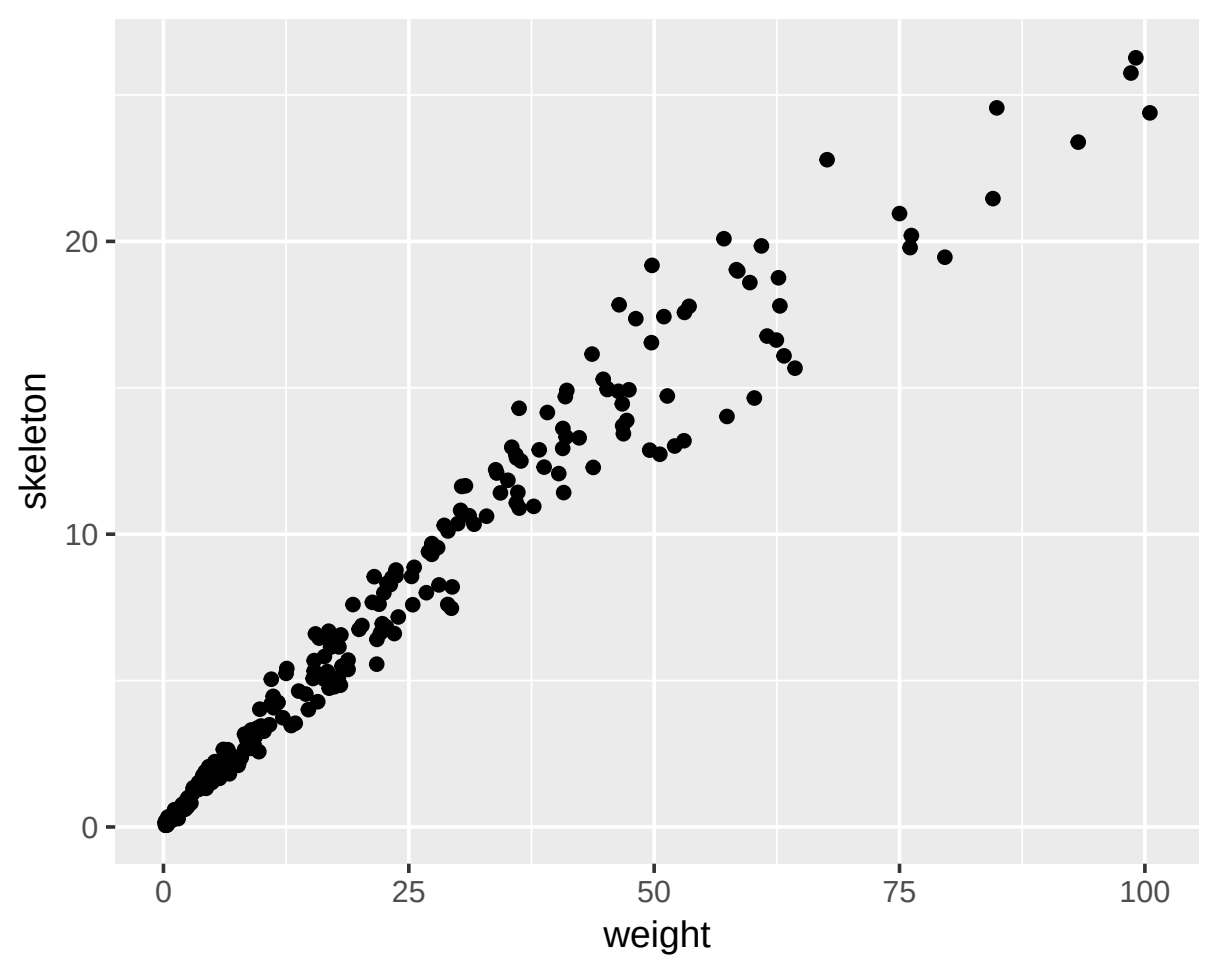

Code facile à comprendre et résultat très plaisant, mais...

- Libellés des axes par défaut sub-optimaux (unités manquantes)
- Thème gris particulier (distingue `ggplot2` des 2 autres)

UMONS

Premier graphique, version `chart`

```
chart(data = urchin, aes(weight, skeleton)) +
  geom_point()
```

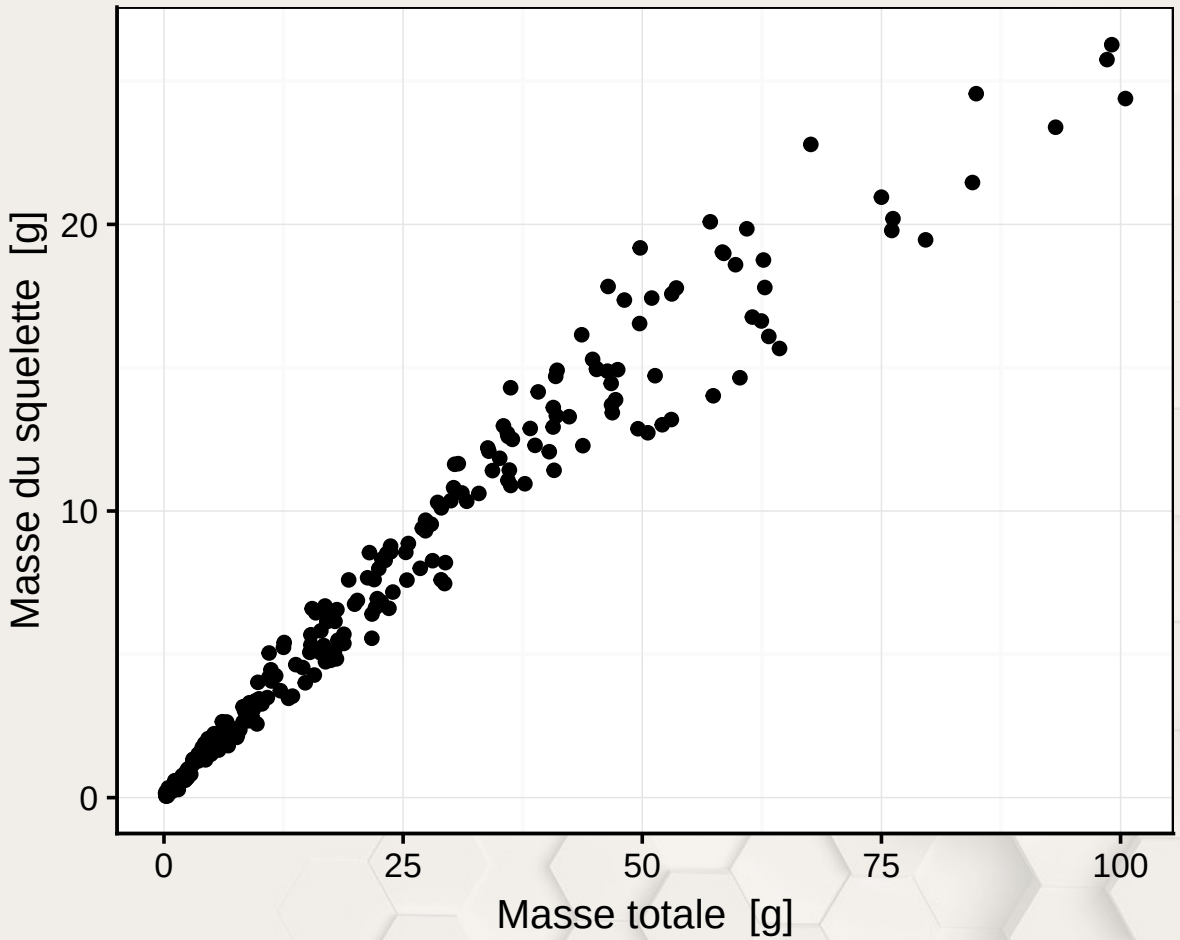

Règle `chart` #1 : `chart()` peut simplement remplacer `ggplot()`.

- Substitution facile à retenir
- Labels des axes et unités automatiques (si renseignés dans le jeu de données)
- Thème plus proche du "publication-ready"

UMONS

Suite logique de l'analyse : régression linéaire

```
(lmod <- lm(data = urchin, skeleton ~ weight))
```

```
Call:
lm(formula = skeleton ~ weight, data = urchin)

Coefficients:
(Intercept)       weight
     0.6882       0.2828
```

Pattern non compatible avec celui du graphique.

- `aes(<x>, <y>)` *versus* `<y> ~ <x>`
- Approche Tidyverse *versus* formula
- Inversion de la position des variables

Comment simplifier vers un pattern unique?

UMONS

Utilisation de formules avec chart

```
chart(data = urchin, skeleton ~ weight) +
  geom_point()
```

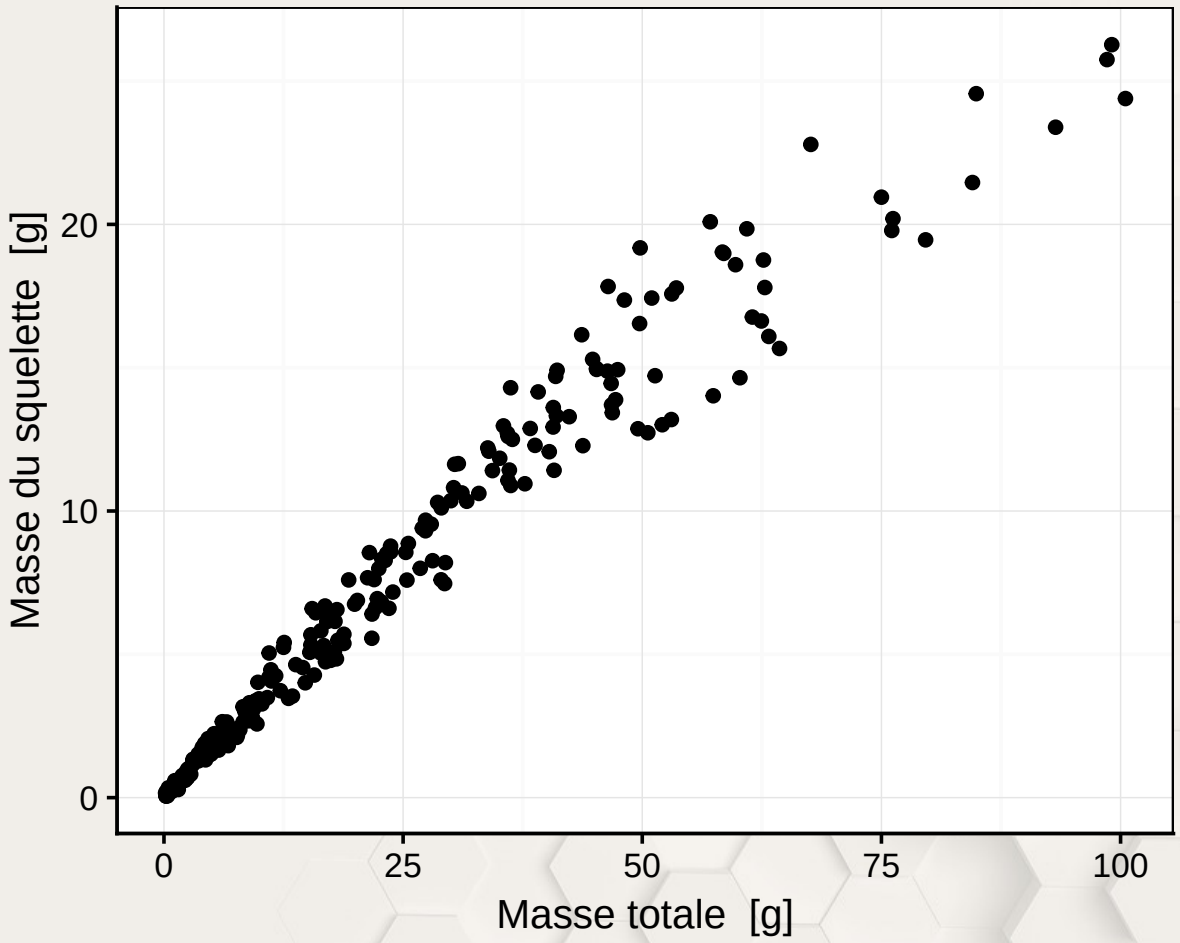

Règle chart #2: une formule est utilisable à la place de aes().

- Convergence vers un pattern identique graphe/modèle dans les cas simples :

```
<fun>(data = <df>,
<formula>)
```

UMONS

`chart$<fun>()` compatible avec lattice et base plots

```
chart$xyplot(data = urchin, skeleton ~ weight)
```

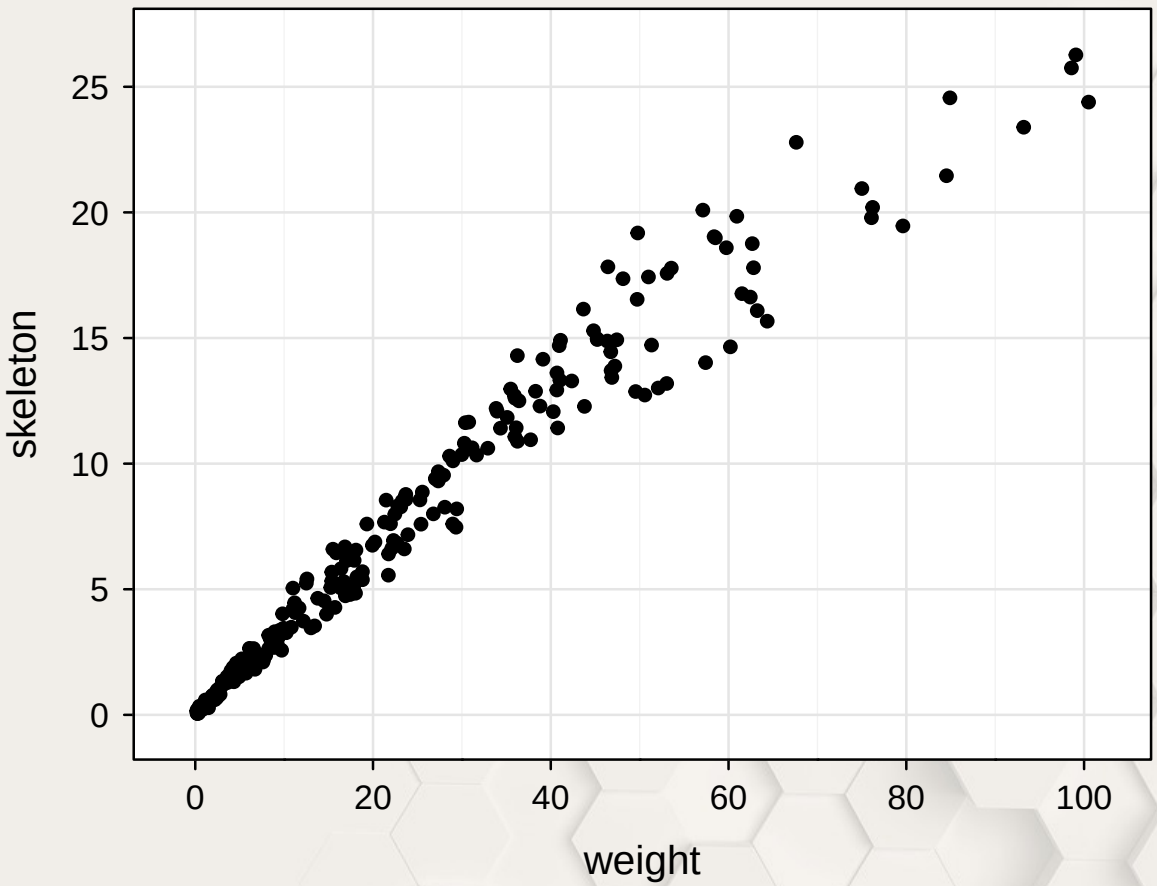

Règle `chart` #3: `chart$<fun>()` permet de varier le type de graphique, y compris base ou lattice !

- Le pattern reste très semblable :

```
<fun>$<type>(data = <df>, <formula>)
```

- Thèmes `ggplot2` / `lattice` / `base` homogènes

UMONS

Ajout de la droite de régression

```
chart$geom_point(data = urchin, skeleton ~ weight) +
  geom_smooth(method = "lm")
```

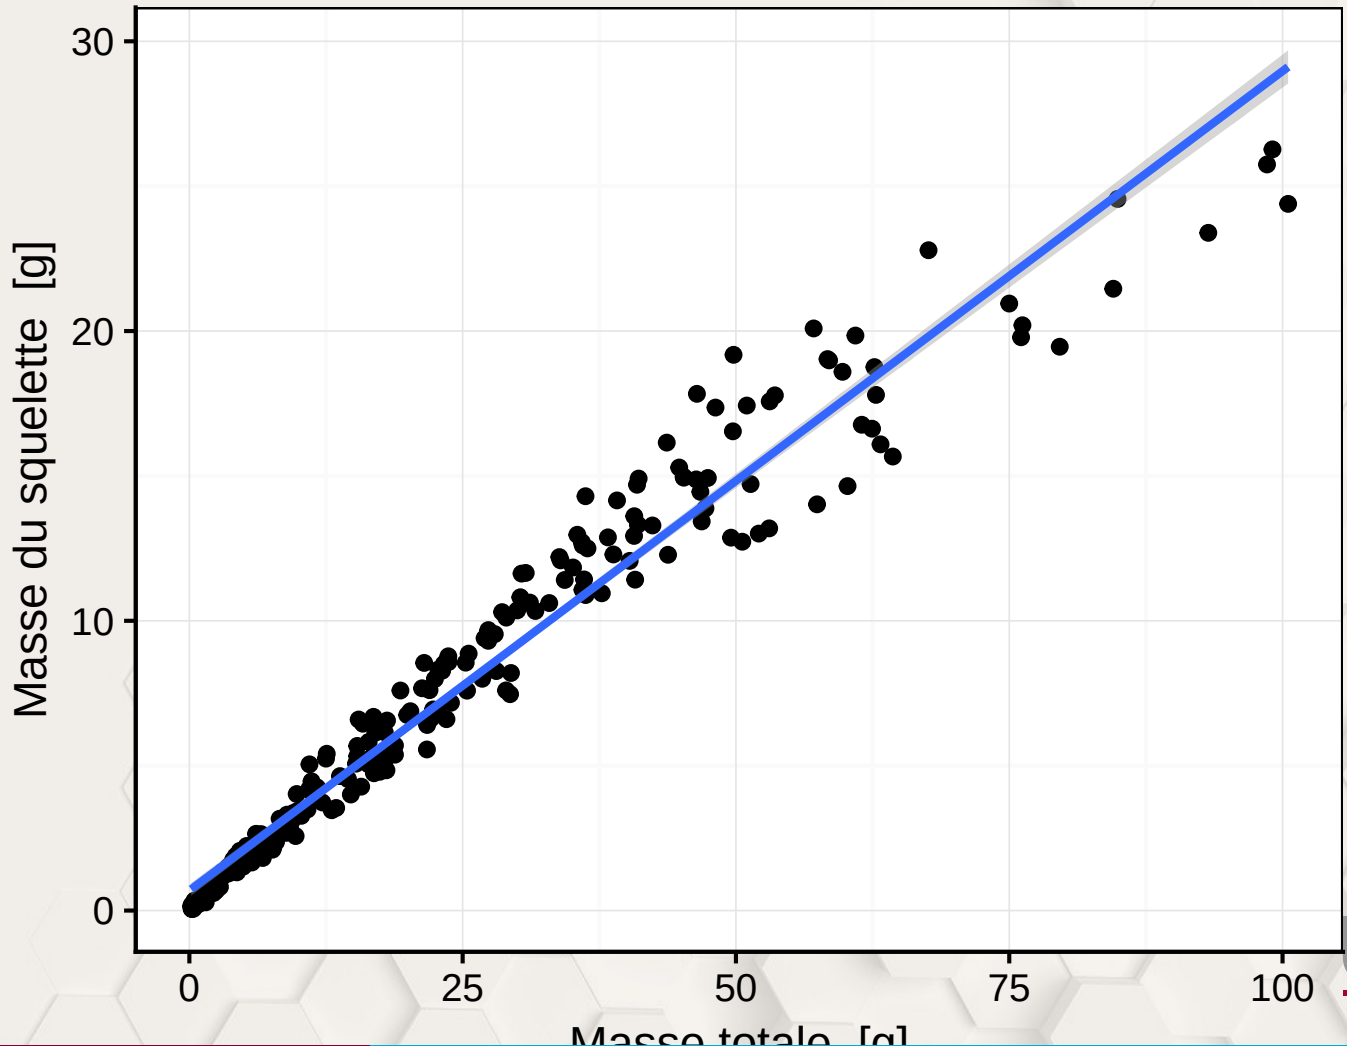

UMONS

Suite de l'analyse : graphe des résidus

```
par(mfrow = c(1L, 2L))
plot(lmod, which = 1L)
plot(lmod, which = 2L)
```

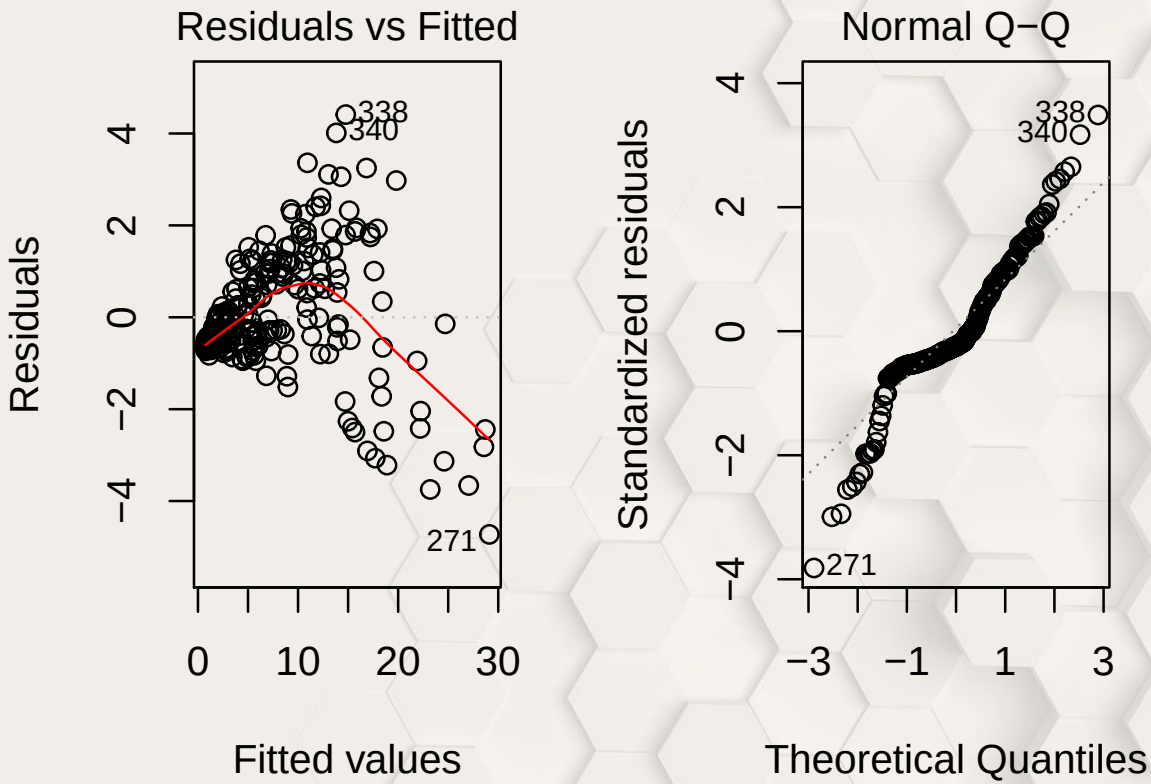

Analyse des résidus de `lm()` => graphiques de base

Comment combiner avec le graphe **`ggplot2`** *précédent dans une figure composite ?*

UMONS

Compatibilité des graphiques `chart` base/lattice/ggplot2 entre eux

Le problème ne se pose plus avec `chart()` : tous les graphes sont compatibles entre eux pour l'assemblage en une figure composite. Démonstration :

```
# ggplot2
c1 <- chart$geom_point(data = urchin, skeleton ~ weight) +
  geom_smooth(method = "lm")
# Lattice plot
c2 <- chart$xyplot(data = urchin, skeleton ~ weight | origin)
# Base plots
c3 <- chart$plot(lmod, which = 1L)
c4 <- chart$plot(lmod, which = 2L)
```

UMONS

```
ggarrange(c1, c2, c3, c4, labels = "AUTO")
```

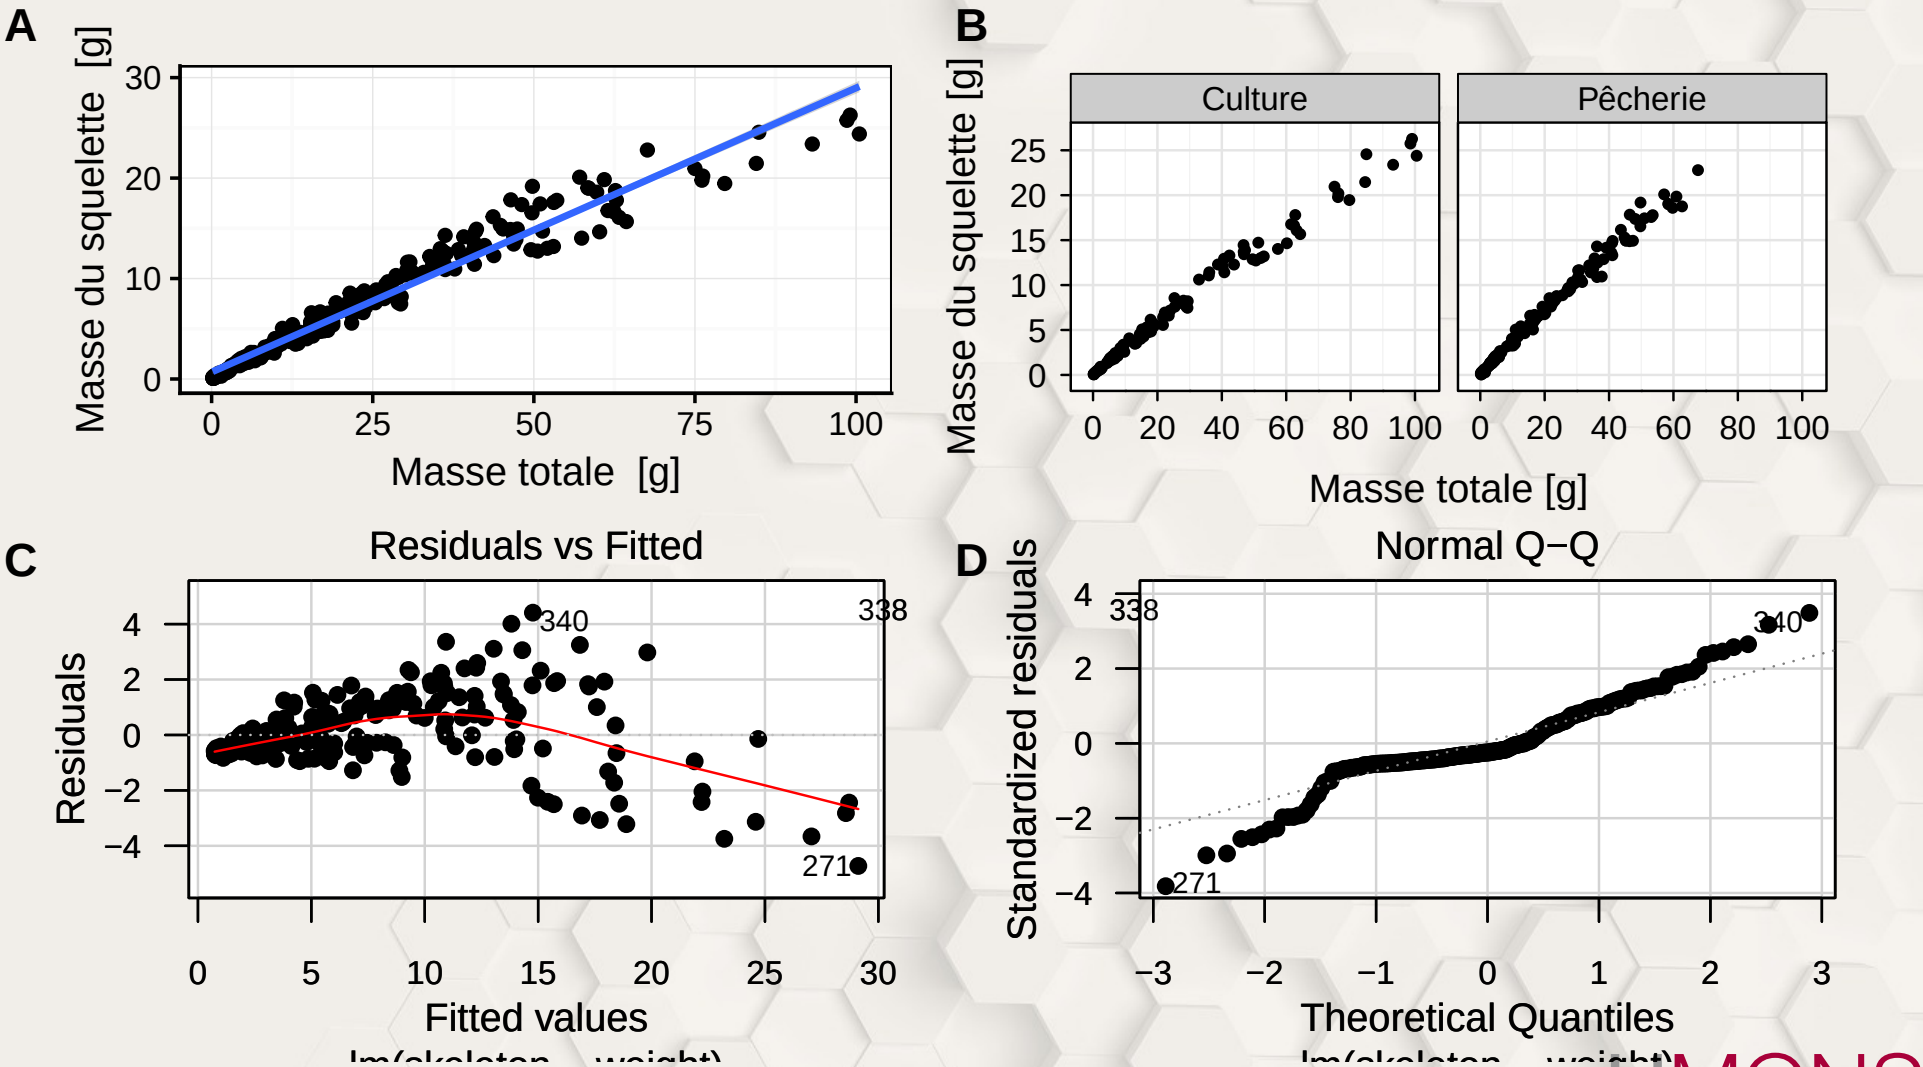

A retenir...

- Les graphiques `chart` peuvent tous être assemblés en une figure composite, qu'ils soient `ggplot2`, graphes de base ou `lattice` *(fini)*
- Les formules sont aussi utilisables avec `ggplot2` en utilisant `chart()` *(fini)*
- Les thèmes des 3 moteurs graphiques sont homogénéisés le plus possible avec `chart` *(encore perfectible)*
- Si des attributs `label` et `units` existent, ils sont utilisés pour de meilleurs labels des axes *(reste à implémenter pour `lattice` et graphes de base)*

Travail en cours... d'autres idées d'améliorations sont les bienvenues, pull request sur https://github.com/SciViews/chart, s'il-vous-plait !

UMONS

Partie II : faciliter la réutilisation de pipelines & tidy évaluation (package flow)

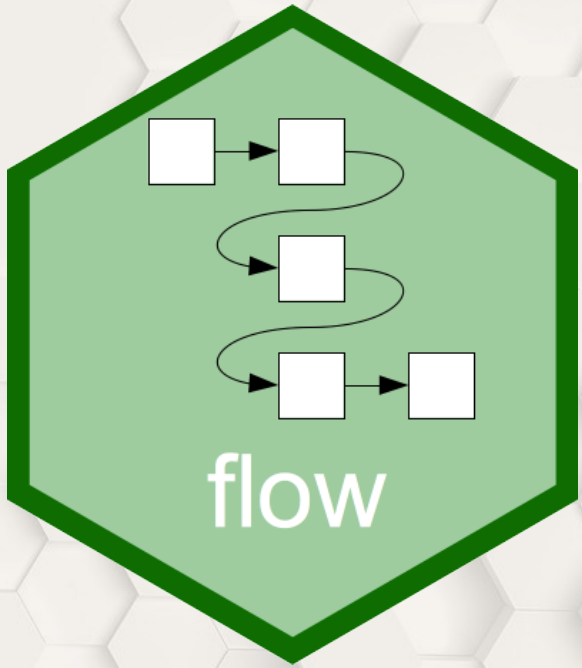

UMONS

Pipeline dans Tidyverse

Voici un exemple de pipeline simple avec `%>%` :

```
urchin %>%
  mutate(lgsk = log(skeleton)) %>%
  summarise(mean = mean(lgsk,
    na.rm = TRUE))
```

mean
1.308811

Comment transformer ce pipeline en fonction réutilisable ?

- Nécessité de maîtriser le mécanisme “tidyeval” de tidyverse => barrière technologique qu’il serait souhaitable de limiter
- Approche par le package `flow` :

```
#devtools::install_github("SciViews/flow")
library(flow)
```

Pipeline dans Tidyverse

Voici un exemple de pipeline simple avec `%>%` :

```
urchin %>%
  mutate(lgsk = log(skeleton)) %>%
  summarise(mean = mean(lgsk,
    na.rm = TRUE))
```

mean
1.308811

Comment transformer ce pipeline en fonction réutilisable ?

- Nécessité de maîtriser le mécanisme “tidyeval” de tidyverse => barrière technologique qu’il serait souhaitable de limiter
- Approche par le package `flow` :

```
#devtools::install_github(”SciViews/flow”)
library(flow)
```

Création d'un objet `flow` : permet d'inclure des variables dans le pipeline

Tidyverse

```
#
x <- quo(skeleton)
urchin %>%
  mutate(lgsk = log(!!x)) %>%
  summarise(mean = mean(lgsk,
    na.rm = TRUE))
```

flow

```
flow(urchin,
  x_ = skeleton
) %>_%
  mutate(., lgsk = log(x_)) %>_%
  summarise(., mean = mean(lgsk,
    na.rm = TRUE)) %>_% .
```

La variable `x_` est incluse dans l'objet `flow`

- Elle ne **"pollue" pas l'environnement** où le pipeline est exécuté, contrairement à ce qui se passe à gauche dans la forme classique
- Opérateur préfixé `!!` (tidyeval) de **tidyverse** est remplacé par l'"opérateur" `_` suffixé dans `flow`
- Le passage d'expressions via les `quosures` devient transparent avec l'"opérateur" suffixé `_` dans `flow`
- la spécification de l'expression est largement simplifiée (pas besoin de `quo()` ou `enquo()`, objectif premier de l'utilisation de l'évaluation non standard !)

Création d'un objet `flow` : permet d'inclure des variables dans le pipeline

Tidyverse

```
#
x <- quo(skeleton)
urchin %>%
  mutate(lgsk = log(!!x)) %>%
  summarise(mean = mean(lgsk,
    na.rm = TRUE))
```

flow

```
flow(urchin,
  x_ = skeleton
) %>_%
  mutate(., lgsk = log(x_)) %>_%
  summarise(., mean = mean(lgsk,
    na.rm = TRUE)) %>_% .
```

La variable `x_` est incluse dans l'objet `flow`

- Elle ne **"pollue" pas l'environnement** où le pipeline est exécuté, contrairement à ce qui se passe à gauche dans la forme classique
- Opérateur préfixé `!!` (tidyeval) de **tidyverse** est remplacé par l'"opérateur" `_` suffixé dans `flow`
- Le passage d'expressions via les `quosures` devient transparent avec l'"opérateur" suffixé `_` dans `flow`
- la spécification de l'expression est largement simplifiée (pas besoin de `quo()` ou `enquo()`, objectif premier de l'utilisation de l'évaluation non standard !)

Variable comme nom d'argument (cas plus difficile)

Tidyverse

```
#
x <- quo(skeleton)
y <- "lgsk"
y_quo <- as.quosure(as.name(y))
urchin %>%
  mutate(!!y := log(!!x)) %>%
  summarise(mean = mean(!!y_quo,
    na.rm = TRUE))
```

flow

```
flow(urchin,
  x_ = skeleton,
  y_ = lgsk

) %>_%
  mutate(., y_ = log(x_)) %>_%
  summarise(., mean = mean(y_,
    na.rm =TRUE)) %>_% .
```

La définition d'un nom de variable et son utilisation ensuite dans un pipeline est beaucoup plus simple avec `flow`

- Une seule variable (`y_`) au lieu de deux (`y` (`character`) et `y_quo` (`quosure`))!
- Pas d'obligation de remplacer `=` par `:=` pour conserver une syntaxe R correcte

UMONS

Variable comme nom d'argument (cas plus difficile)

Tidyverse

```
#
x <- quo(skeleton)
y <- "lgsk"
y_quo <- as.quosure(as.name(y))
urchin %>%
  mutate(!!y := log(!!x)) %>%
  summarise(mean = mean(!!y_quo,
    na.rm = TRUE))
```

flow

```
flow(urchin,
  x_ = skeleton,
  y_ = lgsk

) %>_%
  mutate(., y_ = log(x_)) %>_%
  summarise(., mean = mean(y_,
    na.rm =TRUE)) %>_% .
```

La définition d'un nom de variable et son utilisation ensuite dans un pipeline est beaucoup plus simple avec `flow`

- Une seule variable (`y_`) au lieu de deux (`y` (`character`) et `y_quo` (`quosure`))!
- Pas d'obligation de remplacer `=` par `:=` pour conserver une syntaxe R correcte

UMONS

Fonction réutilisable depuis un pipeline (“séquence fonctionnelle”)

Travail en cours...

Tidyverse

```
#
x <- quo(skeleton)
y <- ”lgsk”
y_quo <- as.quosure(as.name(y))
foo <- . %>%
  mutate(!!y := log(!!x)) %>%
  summarise(mean = mean(!!y_quo,
    na.rm = TRUE))
# Utilisation
foo(urchin)
```

flow

```
foo <- flow_function(urchin,
  x_ = skeleton,
  y_ = lgsk

) %>_%
  mutate(., y_ = log(x_)) %>_%
  summarise(., mean = mean(y_,
    na.rm = TRUE)) %>_% .
# Utilisation, autre variable
foo(urchin, x_ = weight)
```

Seul `flow` permet d’inclure d’autres variables dans la séquence fonctionnelle `foo`

- `flow()` est juste remplacé par `flow_function()`
- Passage à une fonction véritable **beaucoup plus facile et intuitif** à partir de `flow_function()` (conversion automatisée même possible) !

Fonction réutilisable depuis un pipeline (“séquence fonctionnelle”)

Travail en cours...

Tidyverse

```
#
x <- quo(skeleton)
y <- ”lgsk”
y_quo <- as.quosure(as.name(y))
foo <- . %>%
  mutate(!!y := log(!!x)) %>%
  summarise(mean = mean(!!y_quo,
    na.rm = TRUE))
# Utilisation
foo(urchin)
```

flow

```
foo <- flow_function(urchin,
  x_ = skeleton,
  y_ = lgsk

) %>_%
  mutate(., y_ = log(x_)) %>_%
  summarise(., mean = mean(y_,
    na.rm = TRUE)) %>_% .
# Utilisation, autre variable
foo(urchin, x_ = weight)
```

Seul `flow` permet d’inclure d’autres variables dans la séquence fonctionnelle `foo`

- `flow()` est juste remplacé par `flow_function()`
- Passage à une fonction véritable **beaucoup plus facile et intuitif** à partir de `flow_function()` (conversion automatisée même possible) !

A retenir...

- Les objets `flow` contiennent tout ce qui est nécessaire au pipeline, y compris des variables satellites éventuelles
- Le mécanisme “tidyeval” de tidyverse est beaucoup plus facile à implémenter et quasi-totalement transparent avec la convention `<var>_` (“opérateur” suffixé `_`) de `flow`
- Le passage d'un pipeline `flow()` avec variables satellites à une fonction réutilisable est immédiat en remplaçant par `flow_function()`
- La transition pipeline tidyverse à usage unique vers la fonction réutilisable est graduelle et bien plus facile avec `flow`

Un useR devient un developeR en douceuR !

En cours de finalisation et soumission à CRAN... les contributions sont les bienvenues, pull request sur https://github.com/SciViews/flow, s'il-vous-plait !

UMONS

Merci

Avez-vous des questions ?

Présentation et version plus détaillée sous forme de tutorial R Notebook disponibles à

https://github.com/SciViews/RencontresRRennes2018