Améliorer la courbe d'apprentissage de R au delà de Tidyverse ?

Les packages chart et flow



Philippe Grosjean & Guyliann Engels

Université de Mons, Belgique
Laboratoire d'Écologie numérique des Milieux aquatiques
<Philippe.Grosjean@umons.ac.be><https://github.com/SciViews>



Qui sommes-nous?

Biologistes marins (coraux, plancton) à l'Université de Mons en Belgique.





Qui sommes-nous?

- Développeurs en R (mainteneurs de 17 packages sur CRAN dont tcltk2, mlearning, pastecs, zooimage, SciViews, svDialogs, etc.)
- Recherche sur l'évolution et la maintenance logicielles.

An Empirical Study of Identical Function Clones in CRAN

Maëlick Claes, Tom Mens, Narjisse Tabout, Philippe Grosjean Software Engineering Lab & Ecologie numérique des Milieux aquatiques Lab COMPLEXYS Research Institute, University of Mons Email: firstname.lastname@umons.ac.be

Abstract—Code clone analysis is a very active subject of study, and research on inter-project code clones is starting to emerge. In the context of software package repositories specifically, developers are confronted with the choice between depending on code implemented in other packages, or cloning this code in their own package. This article presents an empirical study of identical function clones in the CRAN package archive network, in order to understand the extent of this practice in the R community. Depending on too many packages may hamper maintainability as unexpected conflicts may arise during package updates. Duplicating functions from other packages may reduce maintainability since bug fixes or code changes are not propagated automatically to its clones. We study how the characteristics of cloned functions in CRAN snashots evolve over time, and classify, these clones

Philippe Grosjean & Guyliann Engels

In particular, we want to understand to which extent functions are Type-1 clones across packages, why R package developers clone functions, and if clones could be avoided by the introduction of explicit dependencies. Thus our longitudinal empirical study of inter-package function clones in CRAN focuses on the following research questions:

- How prevalent are clones in CRAN, and how does this evolve over time?
- 2) How and why did clones appear?
- 3) Is it possible to remove clones and how?



Qui sommes-nous?

■ Enseignants, y compris biostatistiques et science des données (voir http://biodatascience-course.sciviews.org)



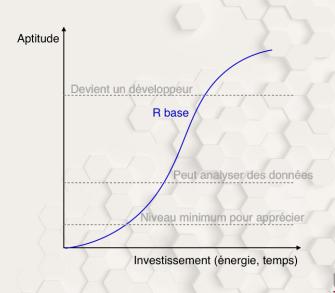


En observant nos étudiants, nous en déduisons les aspects les plus difficiles dans l'apprentissage de R, et nous réfléchissons ensuite à la façon de les simplifier.

Deux exemples seront détaillés ici.

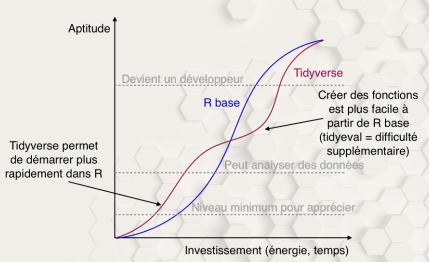


Courbe d'apprentissage de R



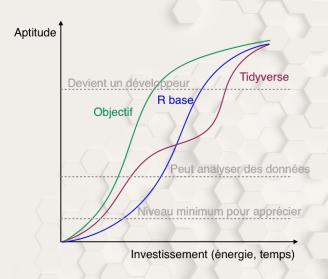


Courbe d'apprentissage de R avec Tidyverse



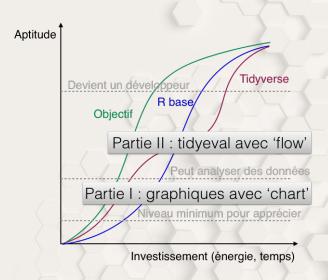


Courbe d'apprentissage idéale





Courbe d'apprentissage idéale





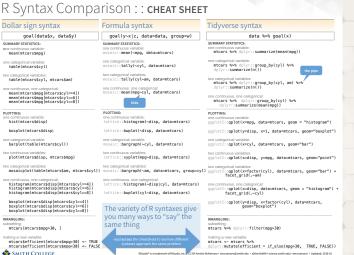
Partie I : faciliter les graphiques R pour les débutants (package chart)





L'écosystème R propose un vaste choix de fonctions

Trois philosophies différentes principales (cf. Amélia McNamara) : **dollar** & **formule** (R base) versus **Tidyverse**





Graphiques sous R

- Trois moteurs graphiques principaux base R ("dollar" et formule), lattice (formule) & ggplot2 (tidyverse)
- Rendu différent, syntaxe différente, incompatibilités
- ggplot2 comme première approche (cf. David Robinson)



David Robinson

Chief Data Scientist at DataCamp,

Don't teach built-in plotting to beginners (teach ggplot2)

I have some experience teaching R programming (see, for instance, my Introduction to the Tidyverse course). One of the atypical choices I make is to start by teaching Hadley Wickham's ggplot2 package, rather than the built-in R plotting.

Many times that I mention this choice to



- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...
- 1 Est-il possible de limiter les dissérences vistelles (thèmes homogenes)?
- 2 Est-il possible de rendre leurs interfac s respectives un peu plus cohérentes
- 3 Est-il possible de les assembler en figures composités

Voyons ensemble quec un exemple très simple d'une analyse par régression linéaixe et le package chart quelques pistes d'améliora son des 3 po its précédents.



- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...
- Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
- 2 Est-il possible de rendre leurs interfac s re sectives un peu slus cohérentes
- Est-il possible de les assembler en figures composit

Voyons ensemble quec un exemple très simple d'une analyse par régression linéaixe et le package chart quelques pistes d'améliora son des 3 po its précédents.



- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...
- 1 Est-il possible de limiter les différences visuelles (thèmes homogènes)?
- Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes?
- 3 Est-il possible de les assembler en figures composités

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaixe et le package chart quelques p<u>iste</u>s d'améliora von des 3 po ets précédents.



- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...
- Est-il possible de limiter les différences visuelles (thèmes homogènes) ?
- Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
- Best-il possible de les assembler en figures composites ?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package chart quelques p<u>iste</u>s d'améliora son des 3 po ets précédents.



- Aucun des 3 moteurs graphiques principaux de R n'est simple (reflet de leurs nombreuses possibilités), mais...
- 1 Est-il possible de limiter les différences visuelles (thèmes homogènes)?
- Est-il possible de rendre leurs interfaces respectives un peu plus cohérentes ?
- **3** Est-il possible de les assembler en figures composites?

Voyons ensemble avec un exemple très simple d'une analyse par régression linéaire et le package chart quelques pistes d'amélioration des 3 points précédents.



Analyse de la masse de squelette d'oursins

Jeu de données urchin_bio dans le package data qui propose aussi une fonction read() pour charger et "enrichir" les jeux de données (label et unité des variables dans différentes langues) :

```
#install.packages("devtools")
#devtools::install_github("SciViews/data")
urchin <- data::read("urchin_bio", package = "data", lang = "FR")</pre>
```

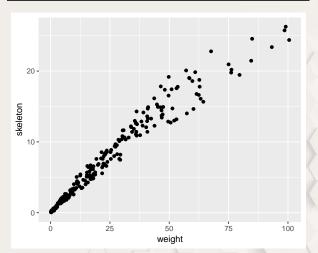
Nous aurons besoin aussi de tidyverse, chart et de leurs dépendances :

```
#install.packages(c("tidyverse", "latticeExtra", "cowplot",
# "pryr", "ggpubr", "ggplotify"))
#devtools::install_github("SciViews/chart")
library(tidyverse)
library(chart)
```

Mettons-nous maintenant dans la peau d'un débutant qui découvre les outils nécessaires pour analyser ces données...

Premier graphique avec ggplot2

```
ggplot(data = urchin, aes(weight, skeleton)) +
  geom_point()
```



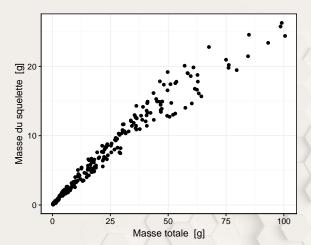
Code facile à comprendre et résultat très plaisant, mais...

- Libellés des axes par défaut sub-optimaux (unités manquantes)
- Thème gris particulier (distingue ggplot2 des 2 autres)



Premier graphique, version chart

```
chart(data = urchin, aes(weight, skeleton)) +
  geom_point()
```



Règle chart #1: chart() peut simplement remplacer ggplot().

- Substitution facile à retenir
- Libellés des axes et unités automatiques (si renseignés dans le jeu de données)
- Thème plus proche du "publication-ready"



Suite logique de l'analyse : régression linéaire

Call:

lm(formula = skeleton ~ weight, data = urchin)

Coefficients:

(Intercept) weight 0.6882 0.2828

Pattern non compatible avec celui du graphique.

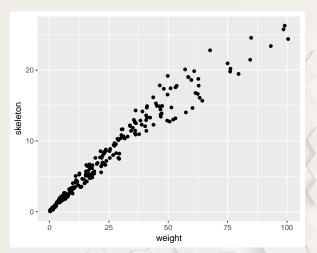
- aes(<x>, <y>) versus
- Approche Tidyverse versus formula
- Inversion de la position des variables

Comment simplifier vers un pattern unique?



Utilisation de formules avec ggplot2

```
ggplot(data = urchin, f_aes(skeleton ~ weight)) +
  geom_point()
```



Règle chart #2: formule f_aes() se substitue à aes().

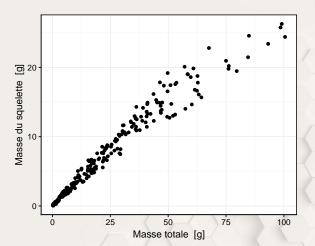
• Convergence vers un pattern identique graphe/modèle dans les cas simples :

<fun>(data = <df>, <formula>)



Utilisation conjointe de formules et de chart()

```
chart(data = urchin, skeleton ~ weight) +
  geom_point()
```



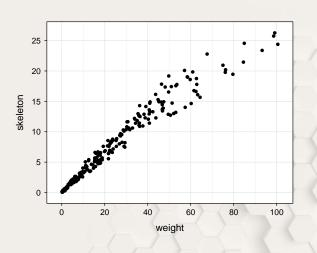
f_aes() est implicite!

Pattern réellement identique entre lm() et chart() plus facile pour le débutant :



chart\$<fun>() compatible avec lattice et base plots

chart\$xyplot(data = urchin, skeleton ~ weight)



Règle chart #3: chart\$<fun>() permet de varier le type de graphique, y compris base ou lattice!

Le pattern reste très semblable :

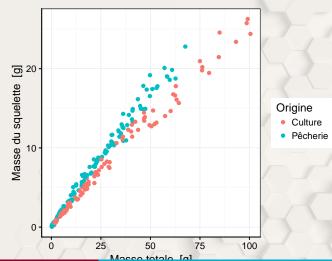
<fun>\$<type>(data = <df>,
<formula>)

Thèmes ggplot2 / lattice / base homogènes



Arguments supplémentaires aes intégrables à la formule avec %<par>=%

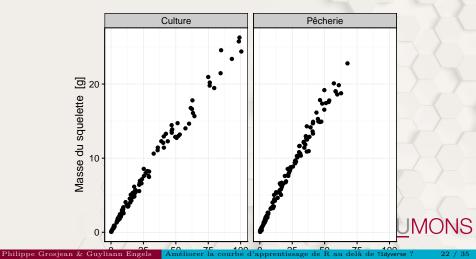
```
#chart$geom_point(data = urchin, skeleton ~ weight, col = origin)
chart$geom_point(data = urchin, skeleton ~ weight %col=% origin)
```



UMONS

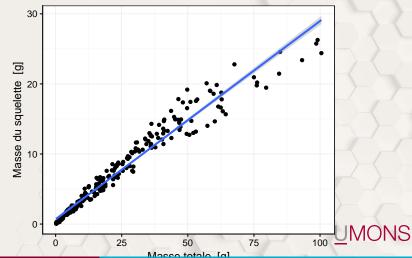
Facettes intégrables dans la formule avec | (= lattice)

```
#chart$geom_point(data = urchin, skeleton ~ weight) +
# facet_wrap(~origin)
chart$geom_point(data = urchin, skeleton ~ weight | origin)
```



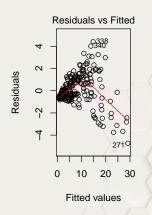
Ajout de la droite de régression

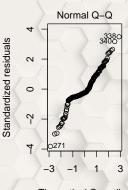
```
chart$geom_point(data = urchin, skeleton ~ weight) +
  geom_smooth(method = "lm")
```



Suite de l'analyse : graphe des résidus

```
par(mfrow = c(1L, 2L))
plot(lmod, which = 1L)
plot(lmod, which = 2L)
```





Analyse des résidus de 1m() => graphiques de base Comment combiner avec le graphe gaplot2 précédent dans une figure composite?



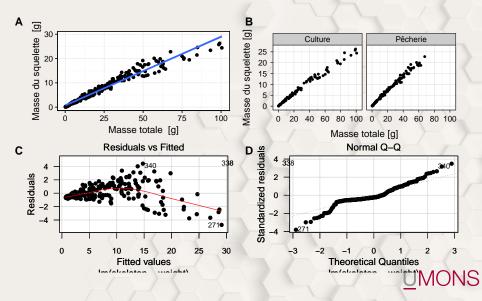


Compatibilité des graphiques chart base/lattice/ggplot2 entre eux

```
# ggplot2
c1 <- chart$geom_point(data = urchin, skeleton ~ weight) +
    geom_smooth(method = "lm")
# Lattice plot
c2 <- chart$xyplot(data = urchin, skeleton ~ weight | origin)
# Base plots
c3 <- chart$plot(lmod, which = 1L)
c4 <- chart$plot(lmod, which = 2L)</pre>
```



ggarrange(c1, c2, c3, c4, labels = "AUTO")



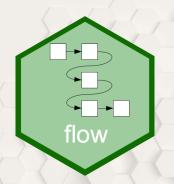
A retenir...

- Les graphiques chart peuvent tous être assemblés en une figure composite, qu'ils soient ggplot2, graphes de base ou lattice (fini)
- Les formules "étendues" sont aussi utilisables avec ggplot2 (fini)
- Les thèmes des 3 moteurs graphiques sont homogénéisés le plus possible avec chart (encore perfectible)
- Si des attributs label et units existent, ils sont utilisés pour de meilleurs labels des axes (reste à implémenter pour lattice et graphes de base)

 $Travail\ en\ cours...\ d'autres\ idées\ d'améliorations\ sont\ les\ bienvenues,\ pull\ request\ sur\ https://github.com/SciViews/chart,\ s'il-vous-plait\ !$



Partie II : faciliter la réutilisation de pipelines & tidy évaluation (package flow)





Pipeline dans Tidyverse

Voici un exemple de pipeline simple avec $\mbox{\ensuremath{\$}}\mbox{\ensuremath{\$}}$:

mean

1.308811

Comment transformer ce pipeline en fonction ratifisable?

Nécessité de maîtriser le mécanismé "tidyeval" de t dyverse => bar nèré technologique qu'il serait soubaita de de limite

Approche par le package flow

```
#devtools::install_github("SciViews/flow")
library(flow)
```

Pipeline dans Tidyverse

Voici un exemple de pipeline simple avec $\sp{8}\sp{8}$:

mean

1.308811

Comment transformer ce pipeline en fonction réutilisable?

- Nécessité de maîtriser le mécanisme "tidyeval" de tidyverse => barrière technologique qu'il serait souhaitable de limiter
- Approche par le package flow :

```
#devtools::install_github("SciViews/flow")
library(flow)
```

Création explicite d'un objet flow : permet d'inclure d'autres variables

Tidyverse

```
flow
```

```
flow(urchin,
  na_rm = TRUE
) %>_%
  mutate(., lgsk = log(skeleton)) %>_%
  summarise(., mean = mean(lgsk,
    na.rm = na_rm_)) %>_% .
```

La variable na_rm est incluse dans l'objet flow

- Elle ne "pollue" pas l'environnement où le pipeline est exécuté, contrairement à ce qui se passe à gauche dans la forme classique
- Opérateur préfixé !! (tidyeval) de tidyverse est remplacé par l'"opérateur" suffixé dans flow



Création explicite d'un objet flow : permet d'inclure d'autres variables

Tidyverse

flow

La variable na_rm est incluse dans l'objet flow

- Elle ne "pollue" pas l'environnement où le pipeline est exécuté, contrairement à ce qui se passe à gauche dans la forme classique
- Opérateur préfixé!! (tidyeval) de tidyverse est remplacé par l'"opérateur" _ suffixé dans flow



Utilisation plus transparente des quosures dans flow

Tidyverse

Une variable flow suffixée de _ crée automatiquement une quosure

- \blacksquare Le passage d'expressions via les quosures devient transparent avec l'opérateur suffixé _ dans flow
- la spécification de l'expression est largement simplifiée (pas besoin de quo() ou enquo(), objectif premier de l'utilisation de l'évaluation non standard !)



Utilisation plus transparente des quosures dans flow

Tidyverse

flow

```
flow(urchin,
    x_ = skeleton,
    na_rm = TRUE
) %>_%
    mutate(., lgsk = log(x_)) %>_%
    summarise(., mean = mean(lgsk,
    na.rm = na_rm_)) %>_% .
```

Une variable flow suffixée de _ crée automatiquement une quosure

- Le passage d'expressions via les quosures devient transparent avec l'opérateur suffixé _ dans flow
- la spécification de l'expression est largement simplifiée (pas besoin de quo() ou enquo(), objectif premier de l'utilisation de l'évaluation non standard !)



Version finale avec trois variables

Tidyverse

low

La définition d'un nom de variable et son utilisation ensuite dans un pipeline est beaucoup plus simple avec ${\sf flow}$

- Une seule variable (y_) au lieu de deux (y (character) et y_quo (quosure))!
- Pas d'obligation de remplacer = par := pour conserver une syntaxe R correcte



Version finale avec trois variables

Tidyverse

flow

La définition d'un nom de variable et son utilisation ensuite dans un pipeline est beaucoup plus simple avec ${\tt flow}$

- Une seule variable (y_) au lieu de deux (y (character) et y_quo (quosure))!
- Pas d'obligation de remplacer = par := pour conserver une syntaxe R correcte



Fonction réutilisable depuis un pipeline ("séquence fonctionnelle")

Travail en cours...

Tidyverse

Seul flow permet d'inclure d'autres variables dans la séquence fonctionnelle foo

- flow() est juste remplacé par flow_function()
- Passage à une fonction véritable beaucoup plus facile et intuitive à partir de flow_function() (conversion automatisée même possible)!

Fonction réutilisable depuis un pipeline ("séquence fonctionnelle")

Travail en cours...

Tidyverse

flow

Seul flow permet d'inclure d'autres variables dans la séquence fonctionnelle foo

- flow() est juste remplacé par flow_function()
- Passage à une fonction véritable beaucoup plus facile et intuitive à partir de flow_function() (conversion automatisée même possible)!

A retenir...

- Les objets flow contiennent tout ce qui est nécessaire au pipeline, y compris des variables satellites éventuelles
- Le mécanisme "tidyeval" de tidyverse est beaucoup plus facile à implémenter et quasi-totalement transparent avec la convention <var>_ de flow
- Le passage d'un pipeline flow() avec variables satellites à une fonction réutilisable est immédiat en remplaçant par flow_function()
- La transition pipeline tidyverse à usage unique vers la fonction réutilisable est graduelle et bien plus facile avec flow

Un useR devient un developeR en douceuR!

En cours de finalisation et soumission à CRAN... les contributions sont les bienvenues, pull request sur https://github.com/SciViews/flow, s'il-vous-plait!



Merci

Avez-vous des questions?

Présentation et version plus détaillée sous forme de R $\bf Notebook$ disponible à https://github.com/SciViews/RencontresRRennes2018

